Inferenza Causale Sequenziale su Processi Non Stazionari

Un Framework BOCD Analitico con Campionamento Informativo e Prior a Legge di Potenza

Antoine Peluso
Università degli Studi di Firenze
Corso di Statistical Learning
Giugno 2026

La "Bugia" dell'Assunzione i.i.d.

I modelli di Changepoint Detection richiedono una condizione fondamentale:

$$x_t \sim N(\mu, \sigma^2) \quad \text{i.i.d. all'interno del regime } \rho$$

Nei dati finanziari campionati a tempo (**Time Bars**), questa assunzione crolla:

- **Eteroschedasticità:** Volatilità clusterizzata (ARCH/GARCH).
- **Non-normalità:** Curtosi estrema e code grasse violano la famiglia esponenziale.
- **Dipendenza seriale:** Autocorrelazione del flusso di ordini.

> ### Conseguenza Statistica
>
> Il posterior bayesiano è numericamente calcolabile, ma **statisticamente inconsistente**. Stiamo fattorizzando una likelihood che non rappresenta la realtà.

Dalla Segmentazione Retrospettiva alla Filtrazione Causale

Approccio Batch (MCMC)

- Retrospettivo (guarda tutto il futuro).
- Complessità O(T) o peggiore.
- Inutile in tempo reale (Alpha Decay).

BOCD Online (Adams & MacKay)

- Causale (solo $x_{1:t}$).
- Aggiornamento ricorsivo locale.
- Complessità **O(1)** per step.

Il Motore di Message Passing

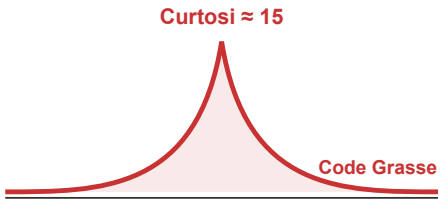
$$P(r_t, x_{1:t}) = \Sigma_{r_{t-1}} [\, P(r_t|r_{t-1}) \cdot P(x_t|r_{t-1}, x_t^{(r)}) \cdot P(r_{t-1}, x_{1:t-1}) \,]$$

Regularizzazione tramite Information-Theoretic Sampling

Invece di campionare a Δt costante, campioniamo a **Informazione costante** (Dollar Bars):

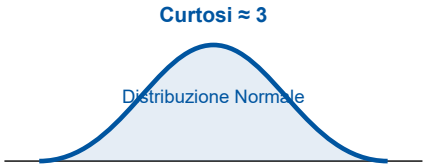
$$B_k = \{ \, tick\ i : \Sigma \, |P_i \cdot Q_i| = V_{target} \, \}$$

Time Bars (Δt)



Violazione i.i.d.

Dollar Bars (ΔV)

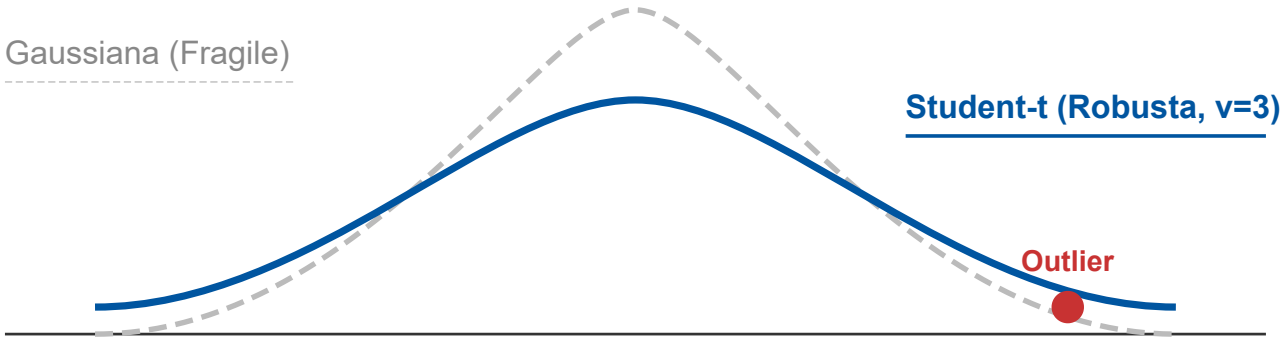


Scambiabilità ripristinata

Robustezza Analitica: Da Gaussiana a Student-t

Sfruttiamo la coniugazione esatta **Normale-Gamma**. Integrando i parametri, la distribuzione predittiva a posteriori è una Student-t:

$$p(x_t \mid x_{1:t-1}) = \text{Student-t}\left(x_t \mid \mu_{t-1}, \beta_{t-1}(\kappa_{t-1}+1)/(\alpha_{t-1}\kappa_{t-1}), 2\alpha_{t-1}\right)$$



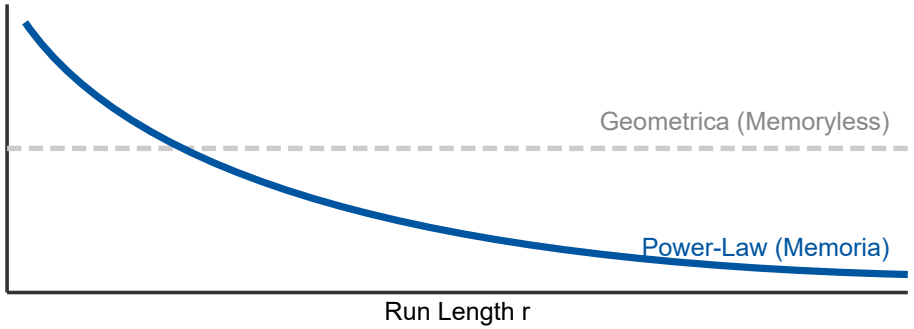
Le code pesanti assorbono lo shock transitorio **senza** generare un falso changepoint.

Survival Analysis dei Regimi: Power-Law Hazard

Il prior geometrico standard è **memoryless** (H(r) = 1/λ). I mercati finanziari hanno **inerzia** (volatility clustering).

Sostituiamo con una Funzione di Hazard a Legge di Potenza:

$$H(r) \propto r^{-\gamma} \quad (\gamma > 0)$$



Più un regime persiste (r alto), minore è la probabilità a priori di un collasso immediato.

Il Motore di Inferenza: Message Passing O(1)

Nessuna approssimazione variazionale. Nessuna catena di Markov. Solo algebra delle **sufficient statistics**.

1. Predict

Calcola π (Student-t)

→

2. Weight

Applica $H(r_{t-1})$

→

3. Update

Aggiorna (μ, κ, α, β)

Complessità

L'aggiornamento delle 4 statistiche sufficienti richiede solo somme e moltiplicazioni. Tempo di esecuzione: **microsecondi**.

Intra-Bar Updating e Associatività Bayesiana

Problema: Rischio di "cecità informativa" se un changepoint avviene *durante* la formazione di una Dollar Bar.

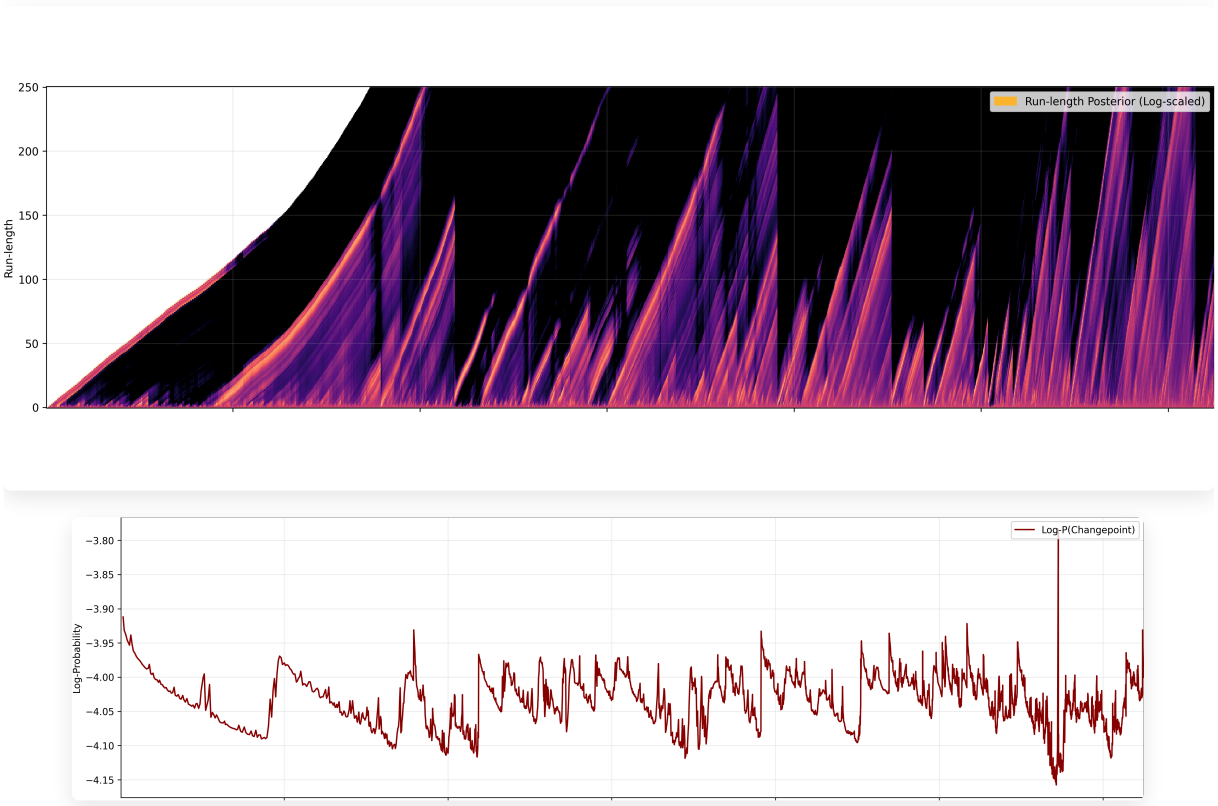
Soluzione: Sfruttare l'associatività del Teorema di Bayes. L'aggiornamento sequenziale su K micro-osservazioni è algebricamente equivalente a un aggiornamento batch:

$$\pi(\theta \mid x_1, \ldots, x_K) \propto \pi(\theta) \prod L(\theta \mid x_i)$$

K aggiornamenti sequenziali ≡ 1 aggiornamento batch

- Ogni frazione del volume target è trattata come n = 1.
- Al passo K, i parametri convergono alla configurazione di un aggiornamento con n = K.

Validazione Empirica: S&P 500 (2000-2024)



Heatmap della Run-Length e Probabilità di Changepoint.

Rilevamento Causale dei Macro-Shock

- **Dot-com (2000):** Rottura della bolla speculativa.
- **Lehman (2008):** Crisi sistemica della liquidità.
- **COVID-19 (2020):** Shock esogeno improvviso.

Efficienza Computazionale

Elaborazione *tick-by-tick* completata in **microsecondi** (O(1)). Nessuna latenza MCMC.

Calibrazione dell'Incertezza: Il Sorpasso della Student-t

Non valutiamo il modello su quanto "indovina" il prezzo, ma su quanto bene **calibra la sua incertezza** tramite l'NLPD (Negative Log-Predictive Density).

Modello Gaussiano (Fragile)

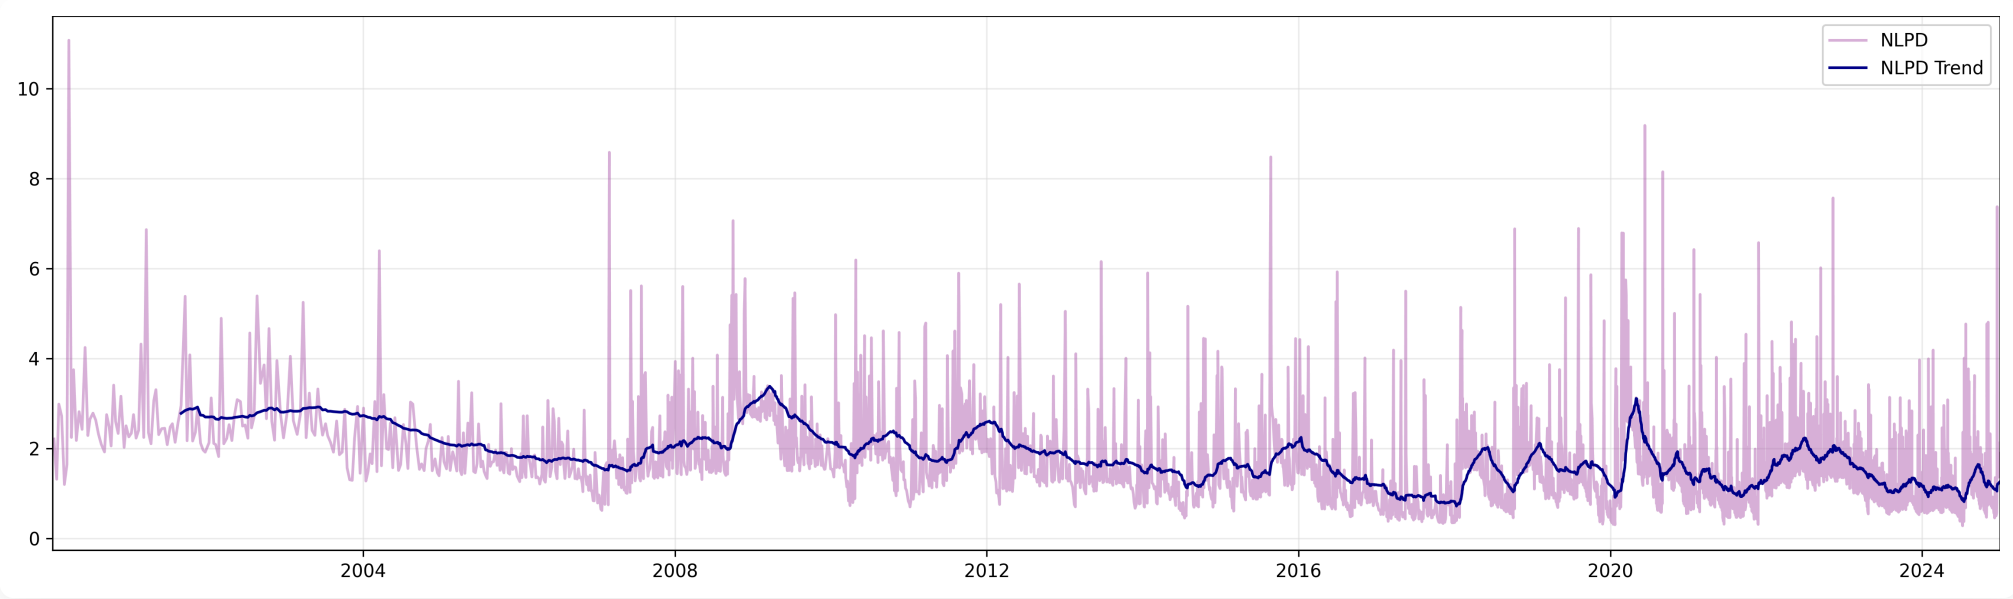
- NLPD ≈ 1.62
- Le code sottili considerano i flash crash come "eventi impossibili".
- **Alto tasso di falsi positivi:** Ogni outlier viene scambiato per un cambio di regime.

Modello BOCD (Student-t)

- **NLPD Media = 1.3855**
- Le code grasse ($v = 2\alpha_{t-1}$) assorbono lo shock.
- **Stabilità:** Il modello rimane "calmo", reagendo solo ai veri struttural breaks.

Risultato Teorico: La Student-t assegna alta probabilità agli eventi estremi prima che accadessero.

Analisi Empirica dell'NLPD nel Tempo



Il trend blu scuro dimostra come il modello calibri dinamicamente l'incertezza. Durante le crisi (es. 2008, 2020), la densità predittiva si adatta **senza collassare**.

Sintesi e Onestà Intellettuale

Punti di Forza

- Inferenza esatta, causale e O(1).
- Robustezza nativa agli outlier (Student-t, NLPD 1.3855).
- Modellazione esplicita dell'inerzia (Power-Law).

Trade-off e Limiti

- **Scambiabilità:** L'Intra-Bar updating assume scambiabilità dei micro-tick.
- **Prior Iniziale:** Sensibilità a $(\mu_0, \kappa_0, \alpha_0, \beta_0)$ nei primissimi step.
- **Memoria:** Necessità di un troncamento R_{max} per evitare allocazione indefinita.

Future Work: Multivariate BOCD

Estensione a processi vettoriali per l'analisi della **correlazione dinamica** tra asset. Attualmente il modello cattura i cambi di varianza, ma non le rotture nella matrice di covarianza (crisi di contagio).

Riferimenti Bibliografici

Adams, R. P., & MacKay, D. J. (2007). *Bayesian Online Changepoint Detection.* arXiv preprint arXiv:0710.3742.
(BOCD, Hazard Function, Posterior Predictive Student-t).

López de Prado, M. (2018). *Advances in Financial Machine Learning.* John Wiley & Sons.
(Dollar Bars, Spilled Samples, Microstruttura).

Cont, R. (2001). *Empirical properties of asset returns: stylized facts and statistical issues.* Quantitative Finance.
(Giustificazione empirica di Volatility Clustering e Fat Tails).

Chipman, H. A., George, E. I., & McCulloch, R. E. (2010). *BART: Bayesian additive regression trees.* The Annals of Applied Statistics.
(Modello di confronto batch, latenza MCMC).

Gottard, A. *Statistical Learning [Materiale didattico].* Università degli Studi di Firenze.
(Slide 25-35: Bayesiana e Coniugazione; Slide 37-46: BART e MCMC).

Grazie per l'attenzione.